


The background of the slide features a close-up photograph of a wine glass filled with white wine, positioned next to a bunch of green grapes resting on a dark wooden surface. The lighting is warm and soft, creating a bokeh effect in the background.

PREVISÃO DA QUALIDADE DE VINHO BASEADA EM TESTES PSICOQUÍMICOS

**Trabalho Final
Machine Learning**

Carolina Martins da Silva

É possível prever a qualidade de um vinho baseada em testes psicoquímicos?


Conseguir prever a qualidade de um vinho de forma exata é tecnicamente desafiante, já que a qualidade deste vai sempre depender de vários fatores, tanto químicos como psicológicos, por exemplo, através da opinião de especialistas em vinhos. No entanto, é algo que tanto a indústria vinícola como os consumidores procuram, uma vez que podem beneficiar de poder de decisão no momento de produção e compra.

Vamos tentar da resposta à pergunta através da utilização da base de dados retirada de <https://archive.ics.uci.edu/dataset/186/wine+quality> usando técnicas de *Machine Learning*. As técnicas usadas para o efeito foram *kNN*, *decision tree*, *random forest* e *svm*. A implementação destas técnicas de *machine learning* podem melhorar a exatidão e eficiência das previsões operacionais, providenciar informação mais objetiva aos consumidores e apoiar a indústria na tomada de decisão.

Exploração e preparação da base de dados

Optei por analisar apenas a base de dados de vinho branco verde, uma vez que são providenciadas duas (tinto e branco), por uma questão de operacionalidade e gosto. Os dados incluem 11 variáveis totais, sendo uma delas a qualidade atribuída pelos especialistas, estando as notas compreendidas em 0 e 10. É possível visualizar a distribuição de vinhos pelas notas no histograma. As restantes variáveis encontram-se retratadas na Tabela 1.

Histograma Qualidade dos Vinhos Brancos



	Min	Max	Média
Acidez fixa(g/dm)	3.800	14.200	6.855
Acidez volátil (g/dm)	0.080	1.100	0.260
Ácido cítrico (g/dm)	0.000	1.660	0.334
Açúcar residual (g/dm)	0.600	65.800	6.391
Cloretos (g/dm)	0.000	0.346	0.0458
Dióxido de enxofre livre (mg/dm)	2.00	35.31	289.00
Dióxido de enxofre total (mg/dm)	9.0	440.0	138.4
Densidade (g/dm)	0.987	1.039	0.994
pH	2.720	3.820	3.188
Sulfitos (g/dm)	0.2200	1.0800	0.4898
Álcool (%vol)	8.00	9.00	5.88

Tabela 1: Dados psicoquímicos (variáveis input) e a estatística correspondente

Foi analisada a existência de possíveis valores nulos, a qual não se verificou. De modo a fazer uma análise de classificação simplificada, devido à quantidade de possibilidade de notas da variável *Qualidade*, optei por atribuir uma classificação baseada na qualidade dos vinhos, em que um vinho com nota igual ou superior a 7 seria considerado um bom vinho. Por outro lado, uma nota inferior a 7, um mau vinho.

Analisando a estrutura do *dataframe*, conseguimos perceber de imediato que os números de “Bom vinho” e “Mau vinho” se encontram desequilibrados. Como tal, de forma a não obtermos números negativamente influenciados, foi efetuado um ajuste através de *downSample* de forma equilibrar os números, como podemos ver nos gráficos seguintes.




Figura 1 - Classificação do vinho




Figura 2 - Classificação do vinho pós downSample

Após equilibrar o *dataframe*, optei por explorar os dados através de gráficos de correlação e frequência das variáveis nas duas classificações de vinho. Analisando o plot de correlação entre as variáveis, conseguimos perceber que variável da classificação do vinho tem uma correlação positiva com a variável álcool, assim como a variável densidade e açúcar residual. Por outro lado, numa correlação negativa, conseguimos ver a densidade e o álcool, ou seja, são inversamente proporcionais.




Figura 4 - Variáveis associadas à Classificação dos Vinhos




Figura 3 - Plot de correlação entre variáveis

Por outro lado, analisando o gráfico de barras das variáveis associadas à classificação dos vinhos, conseguimos visualizar uma frequência maior de valores altos de dióxido de enxofre livre associado a um “Mau vinho”. Conseguimos também perceber que uma frequência de valores mais altos de álcool no “Bom vinho”, corroborando o plot de correlação em que tínhamos percebido uma correlação positiva entre ambos.

Modelos e Técnicas

Após esta exploração, foi feita uma divisão aleatória, entre dados de treino (80%) e dados de teste (20%) de forma a ser possível treinar e testar os modelos que vamos obter com as diferentes técnicas de *machine learning*. Como disse anteriormente, as técnicas escolhidas foram *kNN*, *decision tree*, *random forest* e *svm* uma vez serem técnicas supervisionadas, já que possuímos os dados da qualidade/classificação de cada entrada de dados.

Resultados

Aplicando as técnicas de ML, foram obtidos os seguintes resultados estatísticos apresentados na tabela 2, através de uma *confusion matrix*.

	Accuracy	Falsos "Bom vinho"	Falsos "Mau vinho"
Modelo KNN	73,11%	71	43
Modelo Decision Tree	73,62%	60	53
Modelo Random Forest	90,09%	14	7
Modelo SVM	77,12%	51	46

Tabela 2 - Resultados dos métodos de ML

Conseguimos perceber que, de todos os métodos utilizados, o modelo Random Forest é o que apresenta a maior accuracy, o que significa que errou menos ao prever a qualidade dos vinhos tendo obtido apenas 14 falsos bons vinhos e 7 falsos maus vinhos. Compreende-se o facto de o modelo Random Forest ser mais eficaz que um modelo de Decision Tree, uma vez que o primeiro é um algoritmo que se baseia na criação de múltiplas Decision Trees, aceitando o resultado de previsão de cada uma delas e, baseada na maioria dos votos de previsão, determina o resultado.




Figura 4 Decision Tree




Figura 5 - Importância das variáveis na previsão da qualidade dos vinhos

Conclusão

Analisando o modelo anterior, conseguimos perceber que a percentagem de álcool presente num vinho, a sua densidade e quantidade de cloretos (sal) e açúcar residual tem uma alta importância na previsão da qualidade do mesmo, estando estes associados a uma boa qualidade de vinho. Estes dados corroboram o gráfico de correlação obtido na fase de exploração.

Os restantes modelos, apesar de terem percentagens aceitáveis no que toca à previsão da qualidade, acabam por não conseguir prever de forma tão eficaz. Uma das razões pelas quais os modelos podem não ter obtido resultados tão bons é o baixo número dados treinados obtidos após o downsampling da amostra, que foi realizado para impedir resultados tendenciosos.

No entanto, podemos concluir que, apesar de desafiante, é possível prever a qualidade de um vinho, tendo por base testes psicoquímicos, através de técnicas de *Machine Learning*.